

Gestion des risques

1. Périmètre

Le présent document recense les **risques externes** susceptibles d'impacter les objectifs de collecte, d'intégration et de robustesse du système: **contraintes légales/éthiques, conditions d'accès aux sites web, qualité et disponibilité des sources de données, et dépendances vis-à-vis du client.**

2. Barème

- **Fréquence (F) – 1 à 4 :**

1 : Rare (peu probable sur la durée du projet)

2 : Occasionnel (peut arriver)

3 : Probable (arrive régulièrement)

4 : Fréquent / Très probable (forte probabilité)

- **Gravité (G) – 1 à 4 :**

1 : Faible (impact limité, contournement simple)

2 : Modérée (impact notable, retard/qualité affectés)

3 : Forte (impact important, re-travail significatif)

4 : Critique (blocage, non-respect d'un jalon majeur)

- **Criticité (C = F × G) :**

Plus **C** est élevé, plus le risque est prioritaire

1–2 : faible **3–6** : modéré **8–12** : élevé **16** : critique

3. Tableau des risques

N°	Description	G	F	Criticité	Impacts	Responsable	Prévention	Réponse
1	Changements de structure des sites (infos déplacées / HTML modifié)	4	3	12	Baisse du taux d'extraction, maintenance lourde	Cisco	Système de détection d'erreurs/changements, tests sur sites inconnus	Réparer rapidement, correction manuelle temporaire si nécessaire
2	Indisponibilité ponctuelle d'un site (maintenance courte / panne temporaire)	1	1	1	Ralentissement local de la collecte sur un site	Louison	Suivre l'état des sites critiques, prévoir une liste alternative, relances automatiques	Attendre et relancer, basculer sur un autre site/lot
3	Incohérences des identifiants SIREN entre bases/sources	3	4	12	Données associées au mauvais SIREN, défaut qualité majeur	Yassine	Règles strictes de validation SIREN (format, unicité), contrôles avant intégration	Rollback/correctif, rejouer import, journaliser erreurs, isoler les enregistrements non conformes
4	Scraping limité/interdit	3	4	12	Blocage de collecte, retard, réduction du périmètre	Jean-Baptiste	Audit légal & éthique, définir règles de collecte, privilégier sources autorisées	Stopper la collecte sur les sites non autorisés, basculer vers sources/API autorisées
5	Blocage anti-bot / bannissement (fréquence trop élevée, détection bot)	4	4	16	Arrêt du robot, perte de couverture, retard	Paul	Tester progressivement, limiter cadence, surveiller retours HTTP et logs	Arrêt propre, remplacer le site si besoin, stratégie alternative documentée
6	Erreurs temporaires côté site (timeouts / latence)	2	1	2	Retards ponctuels, besoin de relances	Isidore	Timeouts + retries + backoff, surveillance basique des erreurs	Réessayer plus tard, réduire la charge, mettre le site en attente temporaire
7	Données fausses à la source	2	3	6	Analyses biaisées, perte de confiance	Rana	Traçabilité (URL/date/source), contrôles simples de cohérence	Marquer "suspect", ne pas corriger automatiquement, remonter à l'utilisateur
8	Informations manquantes/inexistantes sur certains sites	3	2	6	Champs vides, couverture partielle	Zhongman	Définir champs minimum, journaliser les champs manquants	Accepter NA, compléter via autres sources autorisées si pertinent