

1) Définition des tâches et périmètre (NLP/IA uniquement)

Entrées : company_id, url, region, siren, raw_text (corpus Web en français).

Sorties : deux tables directement exploitables en aval

- *companies_enriched.csv* : champs structurés (produits/équipements/certifications/clients/adresse...), étiquettes sectorielles multi-étiquettes, maillons de la chaîne de valeur (matières premières / composants / intégration-produit fini / distribution / services), extraits de preuve et URL source ;
- *evidence.csv* : pour chaque décision, phrase déclenchante (snippet) et URL pour audit par les métiers.

Trois missions cœur

A. Extraction d'information (IE, Information Extraction) : extraire depuis le texte français produits/services, équipements/ procédés clés, certifications/agréments, clients/secteurs, adresse/contacts ; conserver pour chaque élément la phrase déclenchante (preuve) et l'URL source.

B. Cartographie sectorielle multi-étiquettes : associer le texte d'entreprise à une ou plusieurs étiquettes Kompass/NACE ; en cas d'incertitude, activer le rejet (open-set) et marquer À vérifier.

C. Mappage des maillons de la chaîne de valeur : projeter l'entreprise sur un ou plusieurs maillons matières premières → composants → intégration/produit fini → distribution → services, avec extrait de preuve.

2) État de l'art

Socle commun — Transformer

La plupart des modèles modernes reposent sur l'architecture Transformer : l'auto-attention relie automatiquement les mots pertinents dans une séquence et gère bien les textes longs ; c'est le socle de BERT, CamemBERT et des approches zéro-shot.

(1) BERT — Pré-apprentissage puis spécialisation légère

BERT apprend une représentation générale de la langue via un pré-apprentissage (masquage de mots à prédire), puis se spécialise avec peu d'exemples pour des tâches comme la reconnaissance d'entités ou la classification. Utile pour renforcer l'IE lorsque règles/lexiques ne suffisent plus.

(2) Sentence-BERT (SBERT) — Vecteurs de phrases comparables

SBERT encode une phrase en vecteur ; des phrases similaires ont des vecteurs proches. À utiliser pour la recherche de textes proches, la déduplication et comme caractéristique sémantique d'appui au rapprochement d'entités (sans trancher la fusion).

(3) CamemBERT — Variante francophone de BERT

CamemBERT est pré-entraîné sur de larges corpus français, offrant une meilleure stabilité en NER et classification sur documents francophones. En cas de performance insuffisante avec règles/zéro-shot, une petite fine-tune supervisée améliore l'extraction (certifications, équipements, clients) et la cartographie (maillons/secteurs).

(4) Classification multi-étiquettes en zéro-shot (via NLI)

Les modèles NLI (inférence naturelle) comme BART-MNLI évaluent si un texte soutient une hypothèse. On reformule chaque étiquette sectorielle comme une phrase hypothèse (ex. « Cette entreprise appartient à l'électronique ») ; le modèle renvoie un score par étiquette. Avantage : aucun entraînement requis pour un premier jet ; en cas de score faible, rejet/à vérifier.

(5) spaCy (pipeline français) — Base CPU

La pipeline française de spaCy (p. ex. `fr_core_news_md`) fournit segmentation, entités nommées (organisation/lieu), etc. Elle sert de socle explicable combiné à lexiques/règles pour un MVP robuste (Minimum Viable Product = version minimale utilisable), avant d'éventuelles montées en gamme par fine-tune.

3) Références (noyau, reconnues)

- Vaswani et al. Attention Is All You Need — socle Transformer (NeurIPS / arXiv).
- Devlin et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding — pré-apprentissage + spécialisation (arXiv).
- Reimers & Gurevych Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks — vecteurs de phrases / recherche de similarité (arXiv).
- Martin et al. CamemBERT: a Tasty French Language Model — modèle francophone (ACL Anthology).
- Hugging Face model card: `facebook/bart-large-mnli` — NLI pour zéro-shot multi-étiquettes.
- spaCy French models — documentation de la pipeline française (`fr_core_news_md`).